TRABALHO DA DISCIPLINA MACHINE LEARNING



Aluno: Carlos Alberto Ferreira Junior - Matrícula: 2022000222
Professor: Pedro Igor
Data: outubro de 2026

UNICARIOCA
Centro Universitário

Estudo de Caso

PREVISÃO DO NÍVEL DE RISCO DE OBESIDADE

Objetivo do Estudo

Construir um modelo de classificação capaz de prever o nível de risco de obesidade.
Utilizar características pessoais, hábitos alimentares e atividade física como variáveis de entrada.
Analisar os dados antes da modelagem e comparar modelos de classificação.
A etapa atual desta apresentação corresponde à Análise Exploratória de Dados.

Visão Geral dos Dataset e Distribuição dos dados

Em resumo, foram disponibilizados para análise, 3 arquivos:

train.csv → arquivo fornecido pelo Kaggle, usado para aprender e validar.

test.csv → arquivo fornecido pelo Kaggle, usado para fazer as previsões finais.

sample_submission.csv → arquivo fornecido pelo Kaggle como modelo de entrega.

Com base no arquivo de exemplo de entrega, será gerado o arquivo abaixo:

submission.csv → arquivo gerado pelo programa em Python (aprendizado_maquina.py) com as previsões do nosso modelo.

Visão Geral dos Dataset e Distribuição dos dados

Arquivo **train.csv — Dataset de treinamento -** É a base principal do trabalho. Ela contém os dados que utilizaremos para **ensinar e avaliar internamente os modelos de Machine Learning**. O arquivo possui **20.758 linhas × 18 colunas**

Cada linha representa um indivíduo. Entre as colunas temos informações como: idade (Age), altura (Height), peso (Weight), consumo de vegetais (FCVC), número de refeições (NCP), consumo de água (CH2O), atividade física (FAF) e outras características.

O ponto fundamental é que o arquivo **train.csv** possui a coluna: **Nobeyesdad** (nível de obesidade do indivíduo). Este campo é a **variável-alvo (target)** e informa a classificação correta daquele indivíduo. Existem sete classes a saber:

Insufficient_Weight - Peso Insuficiente
Normal_Weight - Peso Normal
Overweight_Level_I - Sobrepeso Nível I
Overweight_Level_II - Sobrepeso Nível II
Obesity_Type_I - Obesidade Tipo I
Obesity_Type_II - Obesidade Tipo II
Obesity_Type_III - Obesidade Tipo III

Visão Geral dos Dataset e Distribuição dos dados

UNICARIOCA Centro Universitário

Dados do arquivo **train.csv**

id	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP	CAEC	SMOKE	CH2O	SCC	FAF	TUE	CALC	MTRANS	NObeyesdad
0	Male	24443011	1699998	8166995	yes	yes	20	2983297	Sometimes	no	2763573	no	0	976473	Sometimes	Public_Transportation	Overweight_Level_II
1	Female	180	156	570	yes	yes	20	30	Frequently	no	20	no	10	10	no	Automobile	Normal_Weight
2	Female	180	171146	50165754	yes	yes	1880534	1411685	Sometimes	no	1910378	no	866045	1673584	no	Public_Transportation	Insufficient_Weight
3	Female	20952737	171073	131274851	yes	yes	30	30	Sometimes	no	1674061	no	1467863	780199	Sometimes	Public_Transportation	Obesity_Type_III
4	Male	31641081	1914186	93798055	yes	yes	2679664	1971472	Sometimes	no	1979848	no	1967973	931721	Sometimes	Public_Transportation	Overweight_Level_II
5	Male	18128249	1748524	51552595	yes	yes	2919751	30	Sometimes	no	213755	no	1930033	10	Sometimes	Public_Transportation	Insufficient_Weight
6	Male	29883021	1754711	112725005	yes	yes	199124	30	Sometimes	no	20	no	0	696948	Sometimes	Automobile	Obesity_Type_II
7	Male	29891473	175015	118206565	yes	yes	1397468	30	Sometimes	no	20	no	598655	0	Sometimes	Automobile	Obesity_Type_II
8	Male	170	17	700	no	yes	20	30	Sometimes	no	30	yes	10	10	no	Public_Transportation	Overweight_Level_I
9	Female	260	1638836	111275646	yes	yes	30	30	Sometimes	no	2632253	no	0	218645	Sometimes	Public_Transportation	Obesity_Type_III
10	Female	200	165	650	yes	yes	30	30	Sometimes	no	30	no	10	0	Sometimes	Public_Transportation	Overweight_Level_I
11	Male	220	17	700	yes	no	20	30	no	no	20	no	20	10	no	Walking	Normal_Weight
12	Male	180	1811189	108251044	yes	yes	20	2164839	Sometimes	no	2530157	no	10	553311	no	Public_Transportation	Obesity_Type_I
13	Female	21412538	1729045	131529267	yes	yes	30	30	Sometimes	no	1959531	no	1425712	947884	Sometimes	Public_Transportation	Obesity_Type_III
14	Female	200	157	490	no	no	20	10	Sometimes	no	10	no	30	20	no	Walking	Normal_Weight
15	Male	28377958	1706525	102592171	yes	yes	2636719	30	Sometimes	no	10	no	1995582	930836	Sometimes	Public_Transportation	Obesity_Type_II
16	Female	340	17	800	yes	no	30	30	Always	no	20	no	0	0	no	Automobile	Overweight_Level_II
17	Female	180	156	500	no	yes	30	30	Sometimes	no	10	no	10	0	Sometimes	Public_Transportation	Normal_Weight
18	Male	220	17	800	yes	yes	10	30	Sometimes	no	20	no	0	10	no	Public_Transportation	Overweight_Level_II

Visão Geral dos Dataset e Distribuição dos dados

Arquivo **test.csv** — Dataset de teste do Kaggle – Este arquivo contém novos registros sem a variável-alvo, para os quais o modelo deverá realizar as previsões.

O arquivo test.csv contém **13.840 registros e 17 colunas**. Observe a diferença:

- Arquivo train = **18 colunas**
- Arquivo test = **17 colunas**

Isso ocorre porque o arquivo test.csv **não** possui a variável **Nobeyesdad** (nível de obesidade do indivíduo).

Em outras palavras, o Kaggle nos fornece as características dos indivíduos, mas **não informa a classificação correta**.

O arquivo **test.csv** será utilizado para gerar as previsões que posteriormente serão enviadas ao Kaggle. Após o treinamento do modelo, ele será aplicado aos registros do **test.csv** para prever a variável-alvo NObeyesdad (Nível de Obesidade). Essas previsões serão então armazenadas no arquivo submission.csv, que será enviado ao Kaggle.

Visão Geral dos Dataset e Distribuição dos dados

UNICARIOCA Centro Universitário

Dados do arquivo **test.csv**

id	Gender	Age	Height	Weight	family_history_with_overweight	FAVC	FCVC	NCP	CAEC	SMOKE	CH2O	SCC	FAF	TUE	CALC	MTRANS
20758	Male	26899886	1848294	120644178	yes	yes	2938616	30	Sometimes	no	2825629	no	8554	0	Sometimes	Public_Transportation
20759	Female	210	16	660	yes	yes	20	10	Sometimes	no	30	no	10	0	Sometimes	Public_Transportation
20760	Female	260	1643355	111600553	yes	yes	30	30	Sometimes	no	2621877	no	0	250502	Sometimes	Public_Transportation
20761	Male	20979254	1553127	103669116	yes	yes	20	2977909	Sometimes	no	2786417	no	94851	0	Sometimes	Public_Transportation
20762	Female	260	1627396	104835346	yes	yes	30	30	Sometimes	no	2653531	no	0	741069	Sometimes	Public_Transportation
20763	Male	19799054	1844751	59605028	yes	yes	20	40	Sometimes	no	2722063	no	20	1283673	no	Automobile
20764	Male	180	1728834	51442293	yes	yes	1202075	30	Sometimes	no	1087166	no	788585	10	Sometimes	Public_Transportation
20765	Male	200	181	800	yes	yes	20	30	Always	no	20	no	30	0	no	Automobile
20766	Male	210	17	800	yes	yes	20	30	Frequently	yes	20	no	0	20	no	Public_Transportation
20767	Female	210	156	530	no	yes	20	30	Sometimes	no	20	no	0	10	Sometimes	Public_Transportation
20768	Female	18181821	1535618	41669346	no	yes	2061969	2256119	Sometimes	no	1334856	no	101236	1679442	Sometimes	Public_Transportation
20769	Female	21016665	171978	131927001	yes	yes	30	30	Sometimes	no	2825629	no	1571865	920162	Sometimes	Public_Transportation
20770	Female	260	162456	111883747	yes	yes	30	30	Sometimes	no	2617988	no	0	258472	Sometimes	Public_Transportation
20771	Male	33049121	17	97965532	yes	yes	20	1281683	Sometimes	no	20	no	1987296	1922364	no	Automobile
20772	Female	25966504	173581	104966758	yes	yes	30	30	Sometimes	no	1484938	no	0	966181	Sometimes	Public_Transportation
20773	Male	31755387	187407	92368359	yes	yes	281646	3989492	Sometimes	no	2972426	no	985872	1011983	Sometimes	Automobile
20774	Female	18701766	1603963	80014033	yes	yes	21239	10	Sometimes	no	20	no	753782	0	no	Public_Transportation
20775	Female	260	17	900	yes	yes	30	30	Always	no	30	no	30	0	Sometimes	Automobile
20776	Female	260	1632495	111946655	yes	yes	30	30	Sometimes	no	2770732	no	0	133523	Sometimes	Public_Transportation
20777	Male	22766227	1792533	105686091	yes	yes	20	30	Sometimes	no	2290368	no	1086	463196	Sometimes	Public_Transportation
20778	Male	180	175	700	no	yes	20	30	Sometimes	no	20	no	30	20	no	Walking
20779	Female	24497373	169135	114480696	yes	yes	30	30	Sometimes	no	2509535	no	334264	526776	Sometimes	Public_Transportation

Visão Geral dos Dataset e Distribuição dos dados

Arquivo **sample_submission.csv** — Arquivo que possui o modelo de envio, ou seja, quais dados devem ser enviados ao Kaggle.

id	NObeyesdad
20758	Normal_Weight
20759	Normal_Weight
20760	Normal_Weight
20761	Normal_Weight
20762	Normal_Weight
20763	Normal_Weight
20764	Normal_Weight
20765	Normal_Weight
20766	Normal_Weight
20767	Normal_Weight
20768	Normal_Weight
20769	Normal_Weight
20770	Normal_Weight
20771	Normal_Weight
20772	Normal_Weight
20773	Normal_Weight
20774	Normal_Weight
20775	Normal_Weight
20776	Normal_Weight
20777	Normal_Weight
20778	Normal_Weight
20779	Normal_Weight

Após o treinamento do modelo, será gerado o arquivo **submission.csv**, contendo o campo id do arquivo **test.csv** e a variável **NObeyesdad** (nível de obesidade do indivíduo), preenchida com os valores obtidos pela predição do modelo.

Criação da variável IMC

Foi criada a variável IMC (Índice de Massa Corporal) a partir das variáveis Weight (Peso) e Height (Altura).

Cálculo utilizado: IMC = Peso / Altura².

A mesma transformação foi aplicada às bases de treinamento e de teste.

O IMC será utilizado tanto na análise exploratória quanto posteriormente na modelagem.

Tipos de variáveis

Os tipos de variáveis podem ser enquadrados em 2 categorias, a saber:

Variáveis numéricas:
- Age
- Height
- Weight
- FCVC
- NCP
- CH2O
- FAF
- TUE
- IMC

Variáveis categóricas:
- Gender
- family_history_with_overweight
- FAVC
- CAEC
- SMOKE
- SCC
- CALC
- MTRANS

Variáveis numéricas: São variáveis cujos valores são **números que representam uma quantidade ou medida**. Por isso, conseguimos fazer operações matemáticas com elas, como calcular média, mínimo, máximo e desvio-padrão.

Variáveis categóricas: São variáveis que representam **grupos, classes ou categorias**, mesmo que eventualmente uma categoria pudesse ser codificada com números.

Análise descritiva sobre os atributos

A análise descritiva apresenta medidas como média, desvio-padrão, mínimo, máximo e quartis, permitindo compreender a distribuição e a variabilidade das características numéricas antes da construção dos modelos de Machine Learning.

Variável	Tradução / Significado
id	Identificador — número único de identificação de cada registro
Gender	Gênero — gênero do indivíduo
Age	Idade — idade do indivíduo
Height	Altura — altura do indivíduo
Weight	Peso — peso do indivíduo
family_history_with_overweight	Histórico familiar de sobrepeso — indica se há histórico de sobrepeso na família
FAVC	Consumo frequente de alimentos altamente calóricos — indica se o indivíduo consome frequentemente alimentos com alto valor calórico
FCVC	Frequência de consumo de vegetais — representa a frequência com que o indivíduo consome vegetais
NCP	Número de refeições principais — quantidade de refeições principais realizadas pelo indivíduo
CAEC	Consumo de alimentos entre as refeições — indica a frequência de consumo de alimentos/lanches entre as refeições principais
SMOKE	Fumante — indica se o indivíduo fuma
CH2O	Consumo diário de água — representa a quantidade/frequência de consumo de água
SCC	Monitoramento do consumo de calorias — indica se o indivíduo monitora as calorias consumidas
FAF	Frequência de atividade física — representa a frequência com que pratica atividade
TUE	Tempo de uso de dispositivos tecnológicos — representa o tempo dedicado ao uso de dispositivos eletrônicos/tecnológicos
CALC	Consumo de álcool — representa a frequência de consumo de bebidas alcoólicas
MTRANS	Meio de transporte utilizado — indica o principal meio de transporte do indivíduo
NObeyesdad	Nível de obesidade — classificação do nível de peso/obesidade do indivíduo; é a variável-alvo (target) que queremos prever

Análise descritiva sobre os atributos

UNICARIOCA Centro Universitário

Variáveis Numéricas

Variável	Média	Desvio-padrão	Mínimo	25% (1º quartil)	50% (Mediana ou 2º quartil)	75% (3º quartil)	Máximo
Age	23,84	5,68	14,00	20,00	22,81	26,00	61,00
Height	1,70	0,08	1,45	1,63	1,70	1,76	1,97
Weight	87,88	26,37	39,00	66,00	84,06	111,60	165,05
FCVC	2,44	0,53	1,00	2,00	2,39	3,00	3,00
NCP	2,76	0,70	1,00	3,00	3,00	3,00	4,00
CH2O	2,02	0,60	1,00	1,79	2,00	2,54	3,00
FAF	0,98	0,83	0,00	0,00	1,00	1,58	3,00
TUE	0,61	0,60	0,00	0,00	0,57	1,00	2,00
IMC	30,24	8,33	12,86	24,08	29,38	37,01	54,99

Legenda	
Média	Valor médio da variável
Desvio-padrão	Quanto os valores variam em relação à média
Mínimo	Menor valor encontrado
1º quartil	25% dos registros estão abaixo ou iguais a esse valor
Mediana	Metade dos registros está abaixo e metade acima
3º quartil	75% dos registros estão abaixo ou iguais a esse valor
Máximo	Maior valor encontrado

Análise descritiva sobre os atributos

UNICARIOCA Centro Universitário

Variáveis Categóricas

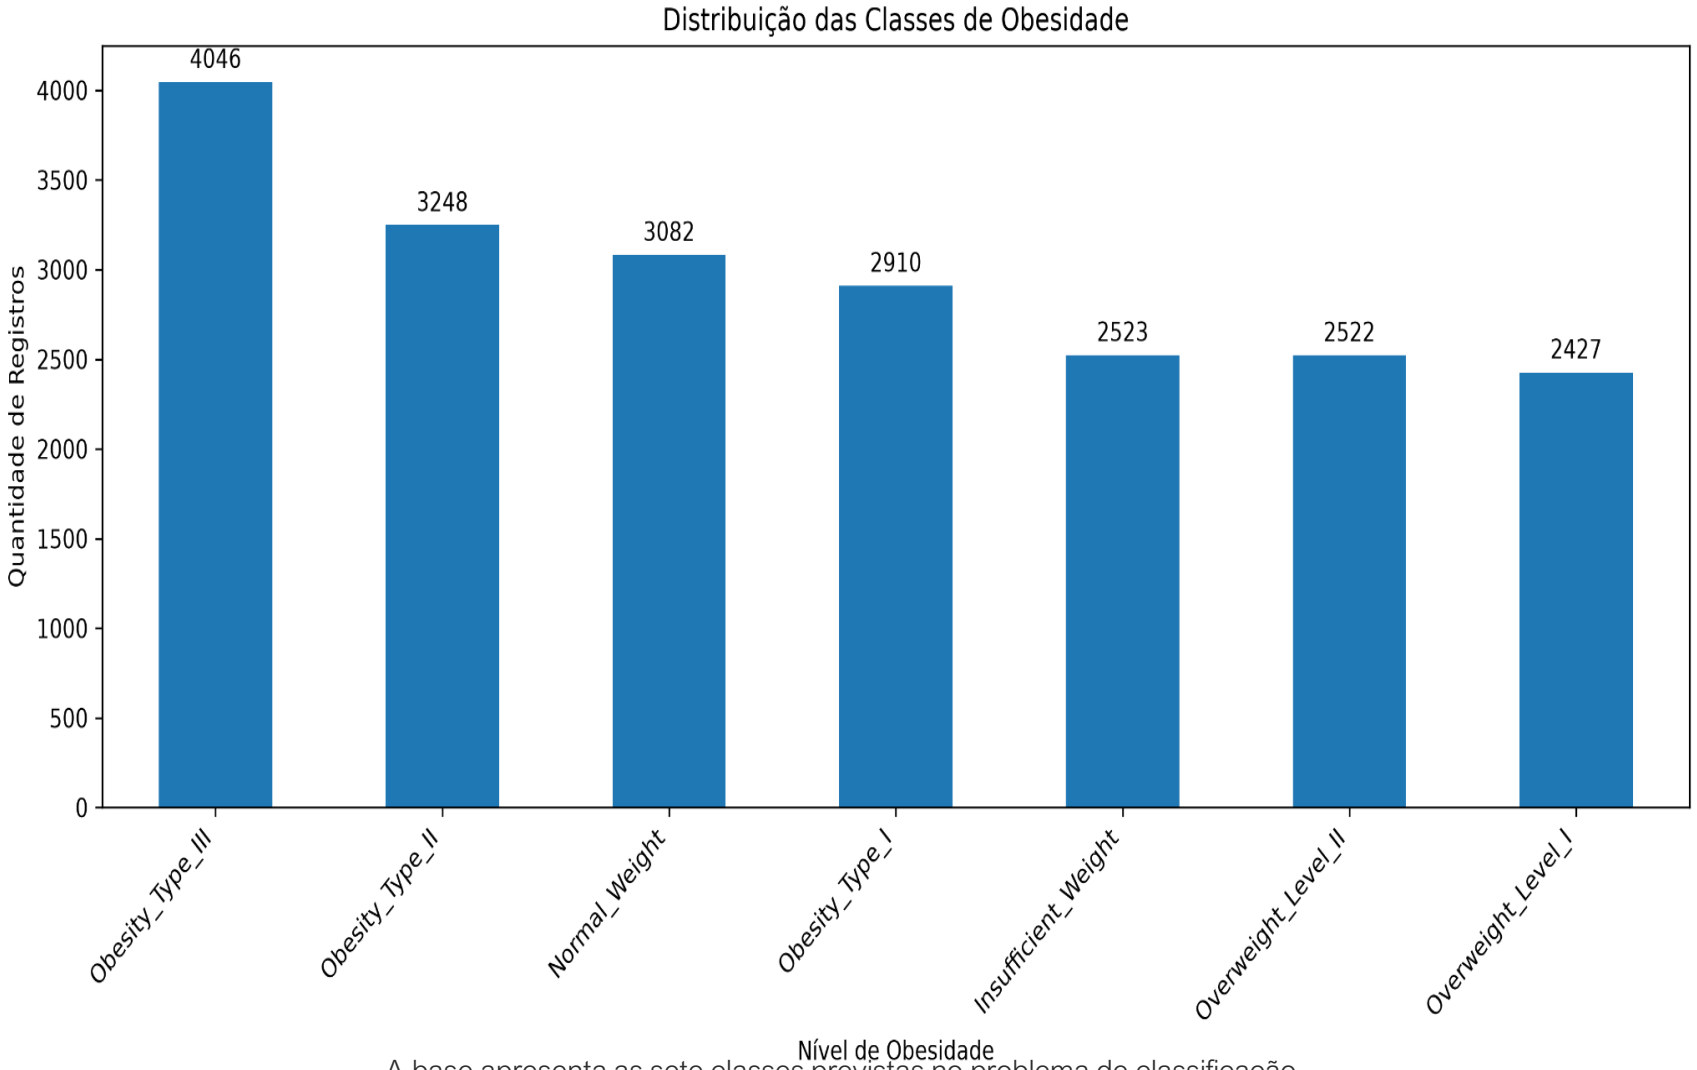
Variável	Valores Distintos	Maior incidência	Quantidade
Gender	2	Female	10422
family_history_with_overweight	2	yes	17014
FAVC	2	yes	18982
CAEC	4	Sometimes	17529
SMOKE	2	no	20513
SCC	2	no	20071
CALC	3	Sometimes	15066
MTRANS	5	Public_Transportation	16687

Análise descritiva sobre os atributos

Variável Alvo

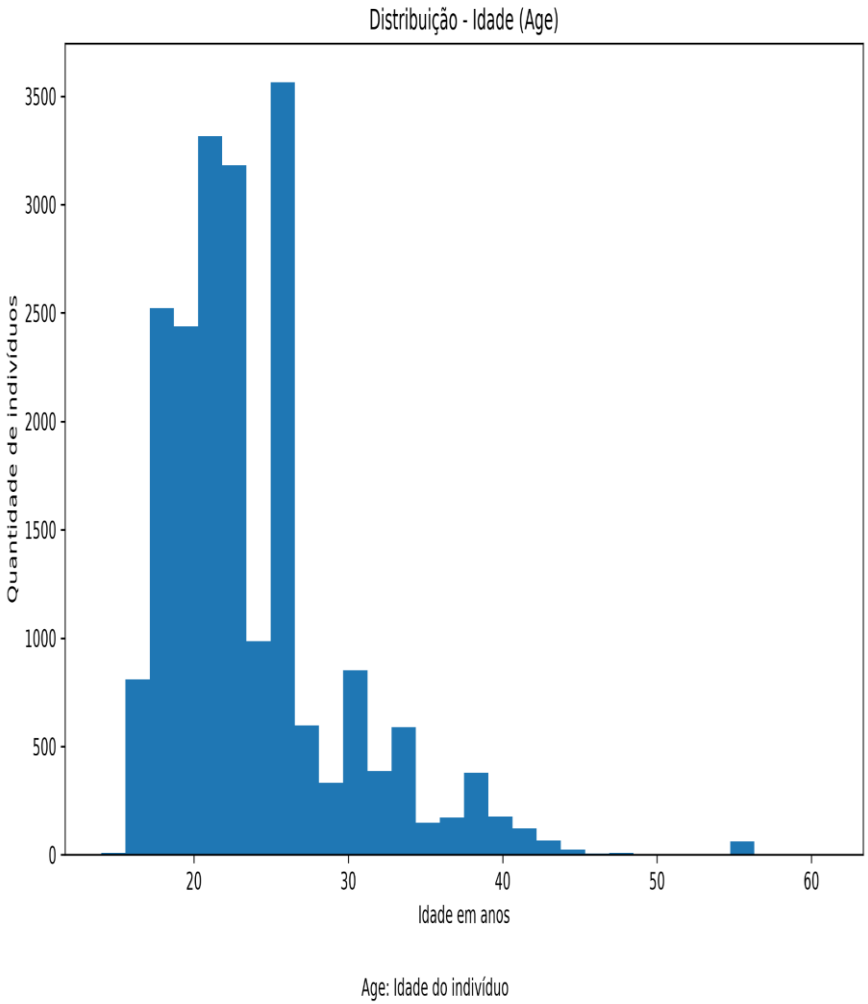
Percentual por classe		
NObeyesdad	**%**	**Quantidade**
Obesity_Type_III	19,49	4046
Obesity_Type_II	15,65	3248
Normal_Weight	14,85	3082
Obesity_Type_I	14,02	2910
Insufficient_Weight	12,15	2523
Overweight_Level_II	12,15	2522
Overweight_Level_I	11,69	2427
Total:	**100**	**20758**

Distribuição das classes de obesidade



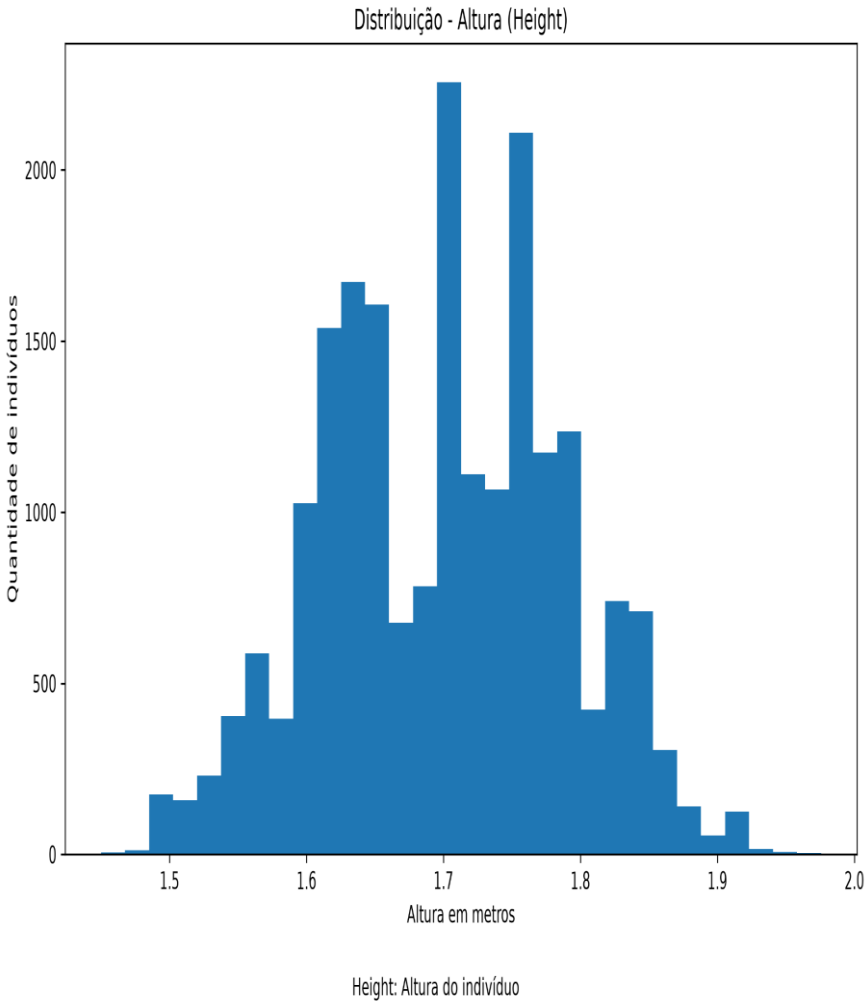
A base apresenta as sete classes previstas no problema de classificação.

Distribuições de idade e altura



Age: Idade do indivíduo

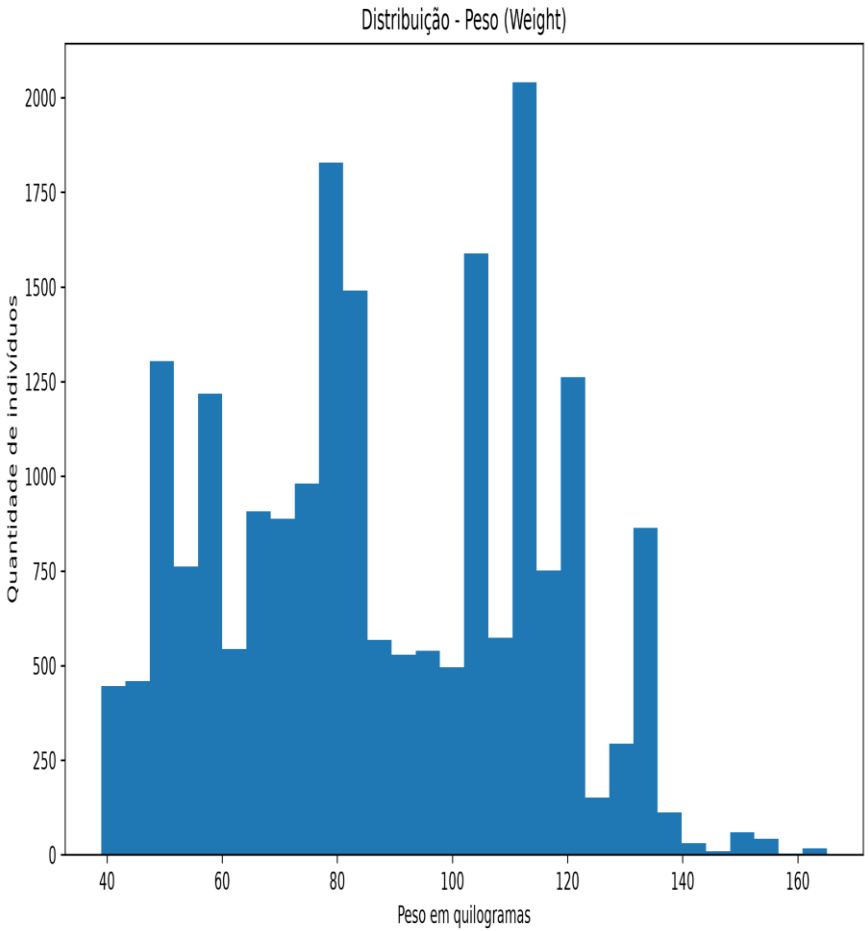
Age — Idade



Height: Altura do indivíduo

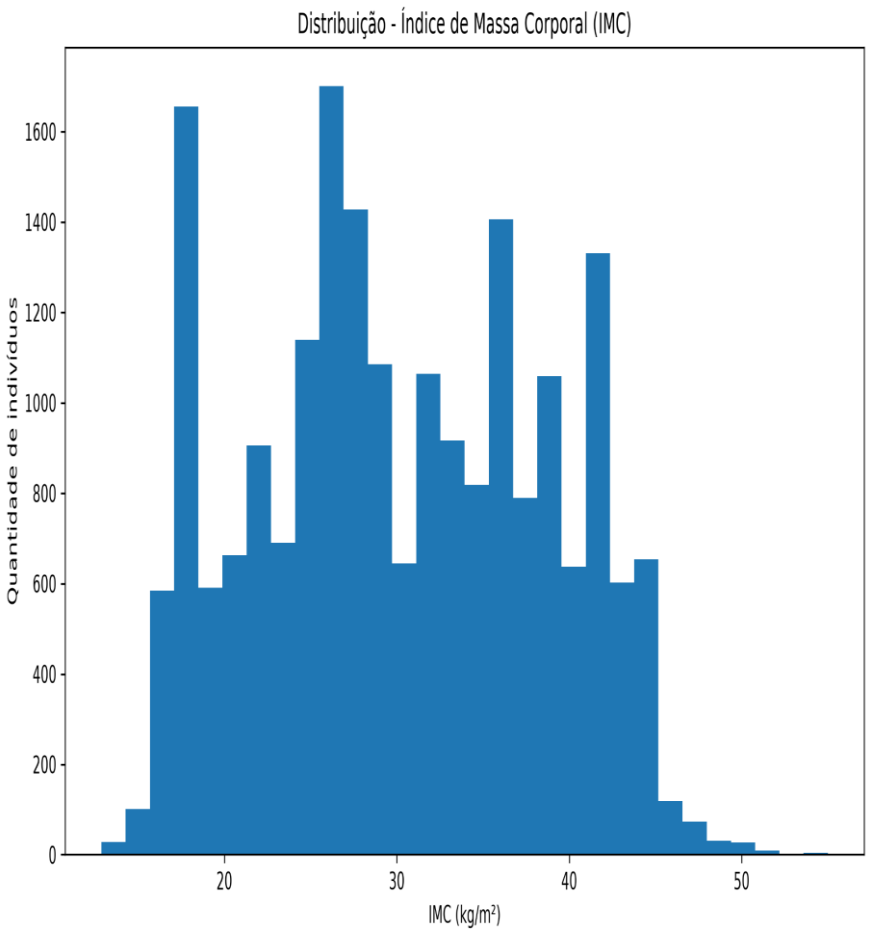
Height — Altura

Distribuições de peso e IMC



Weight: Peso corporal do indivíduo

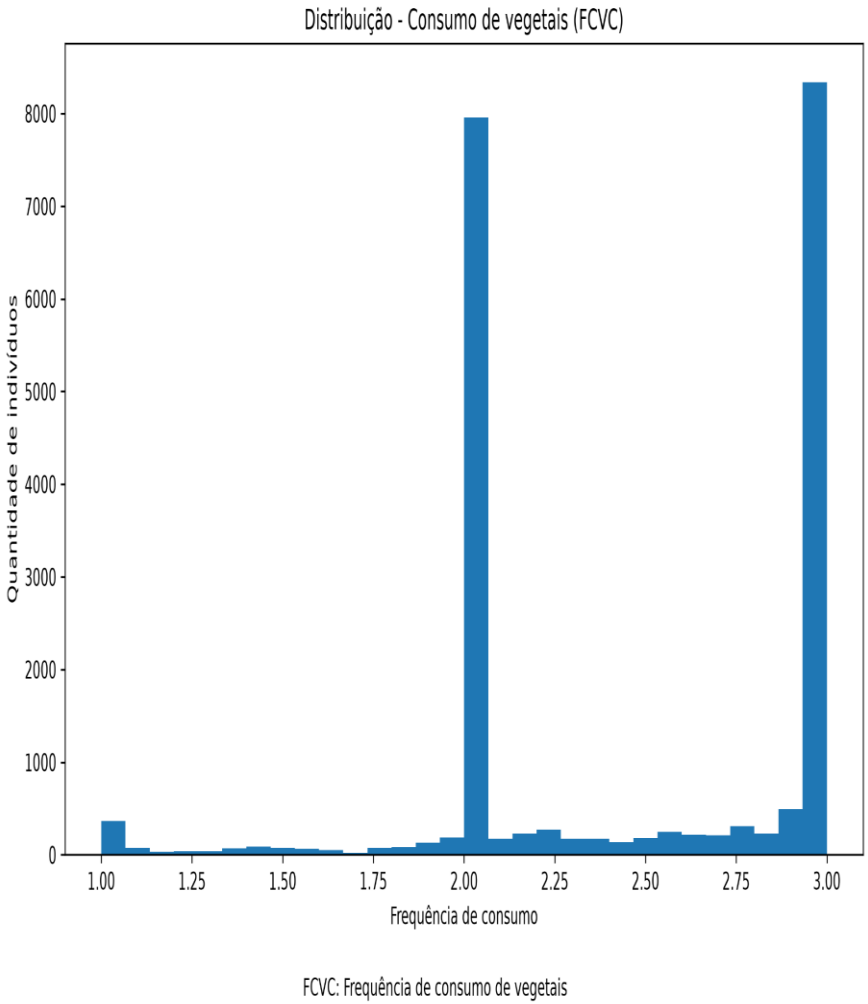
Weight — Peso corporal



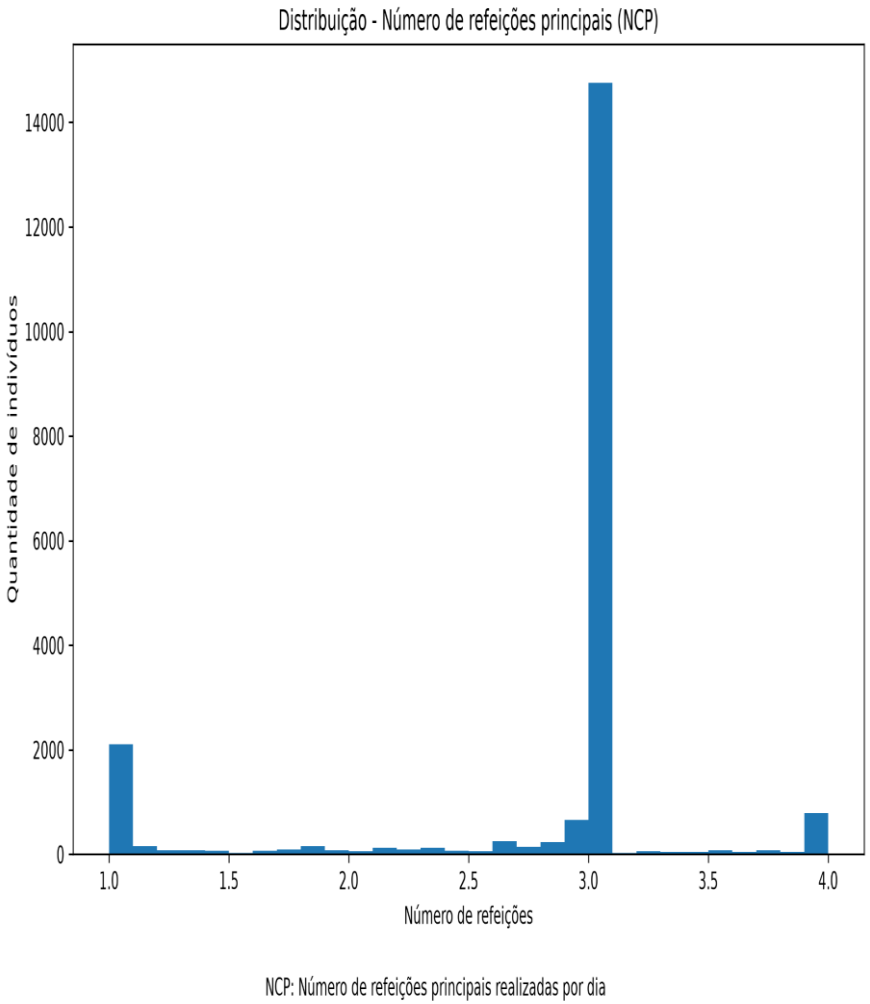
IMC: Índice calculado a partir do peso e da altura

IMC — Índice de Massa Corporal

Hábitos alimentares

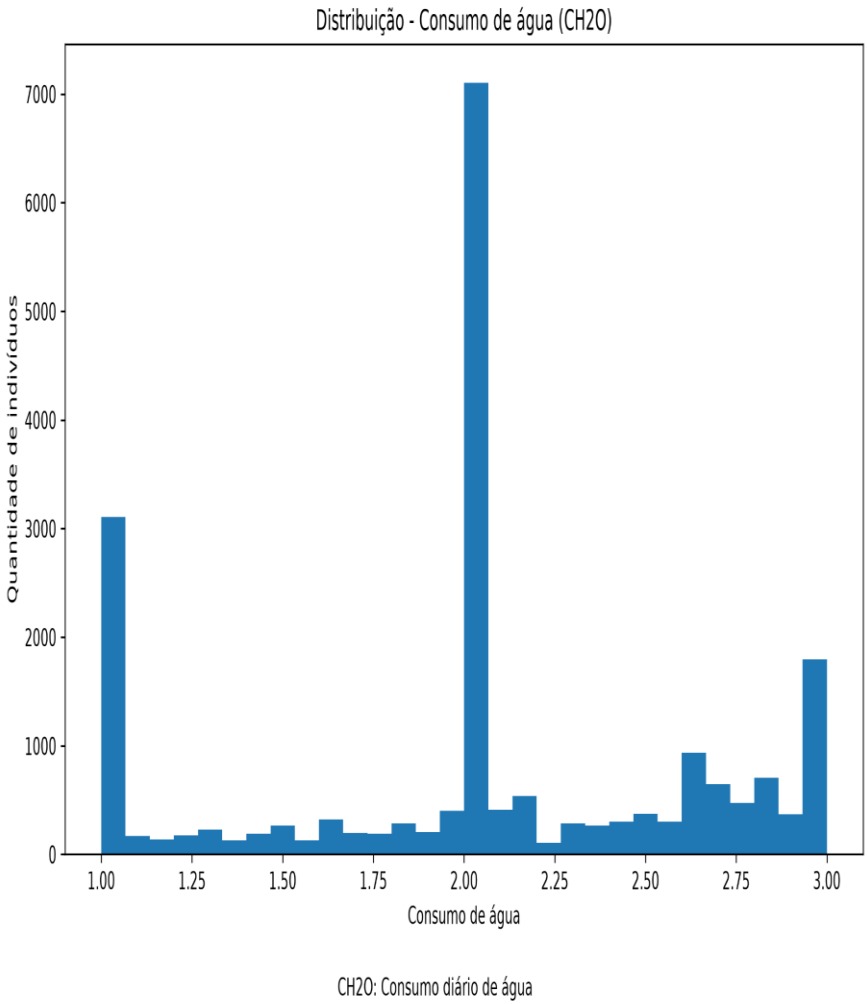


FCVC — Frequência de consumo de vegetais

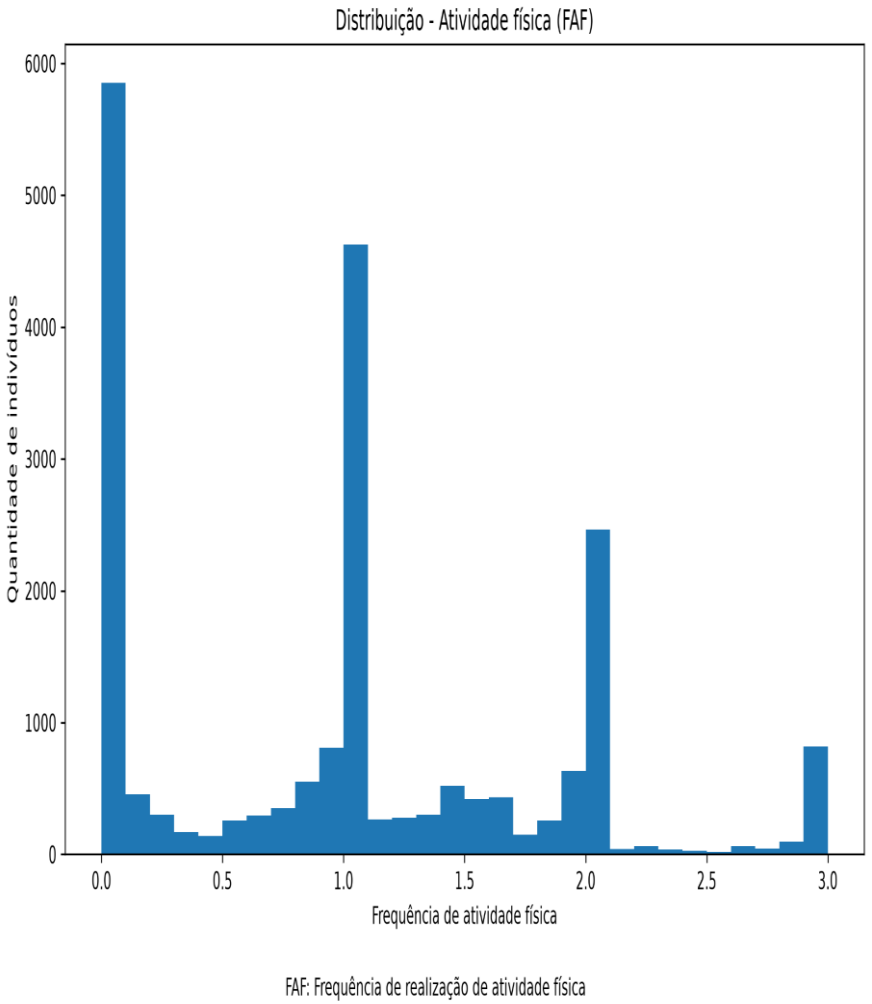


NCP — Número de refeições principais

Água e atividade física

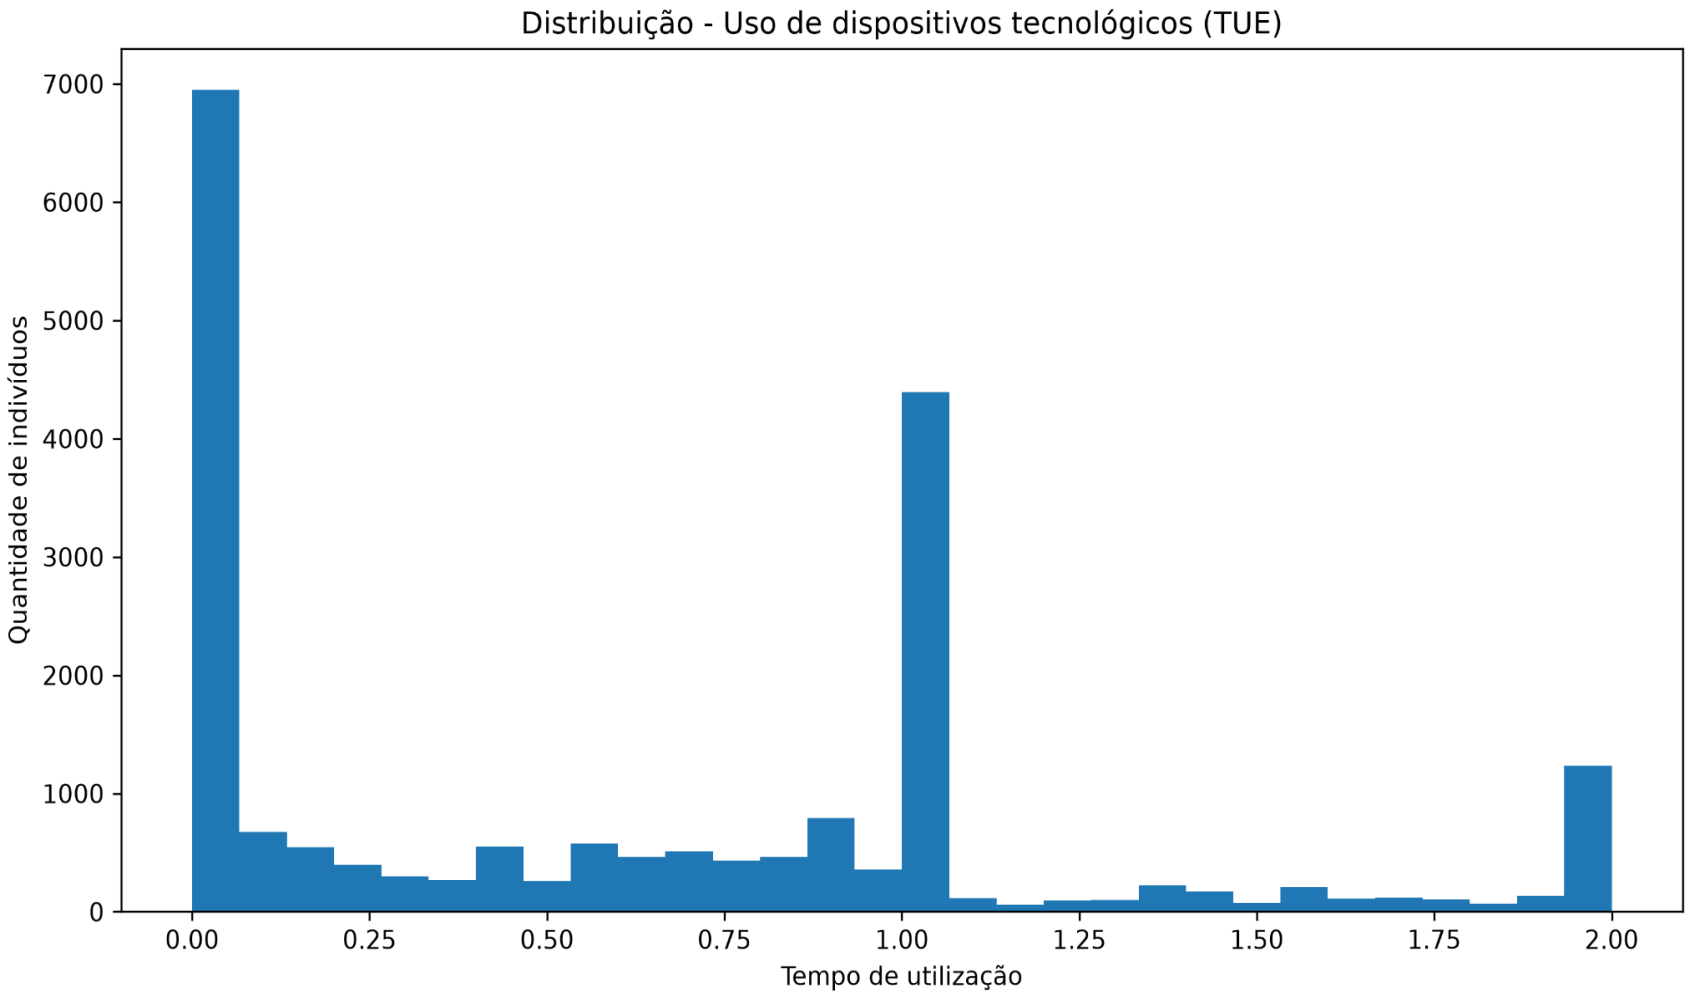


CH2O — Consumo diário de água



FAF — Frequência de atividade física

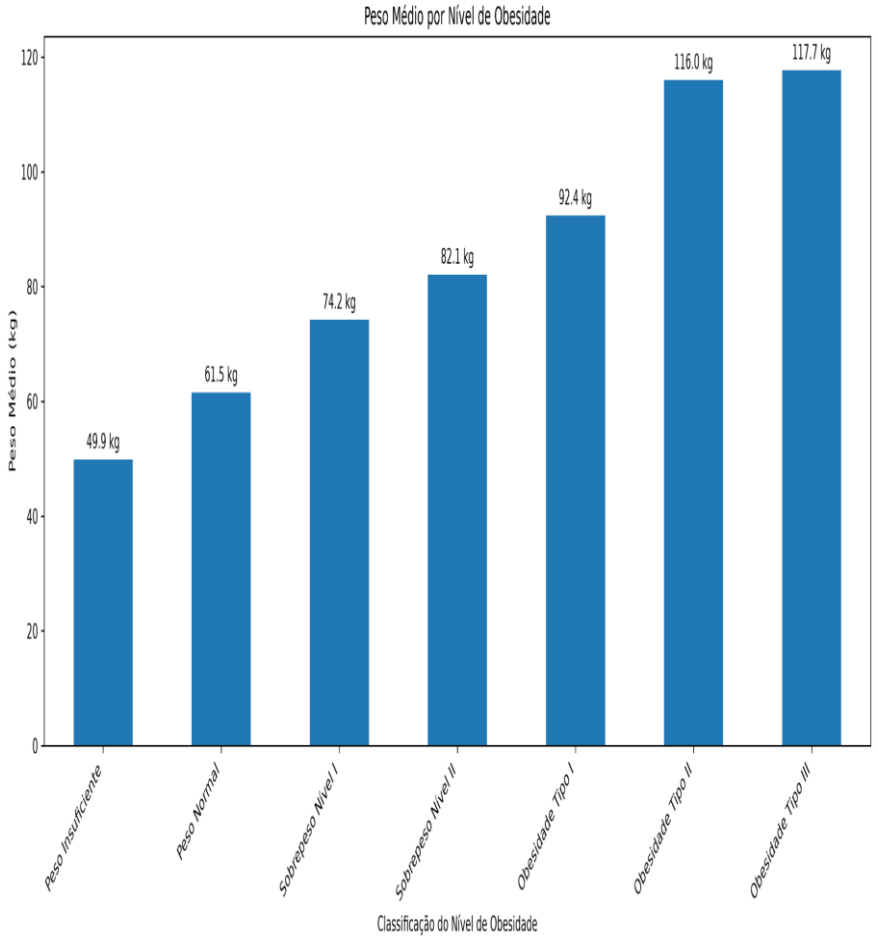
Uso de dispositivos tecnológicos



TUE: Tempo de utilização de dispositivos tecnológicos

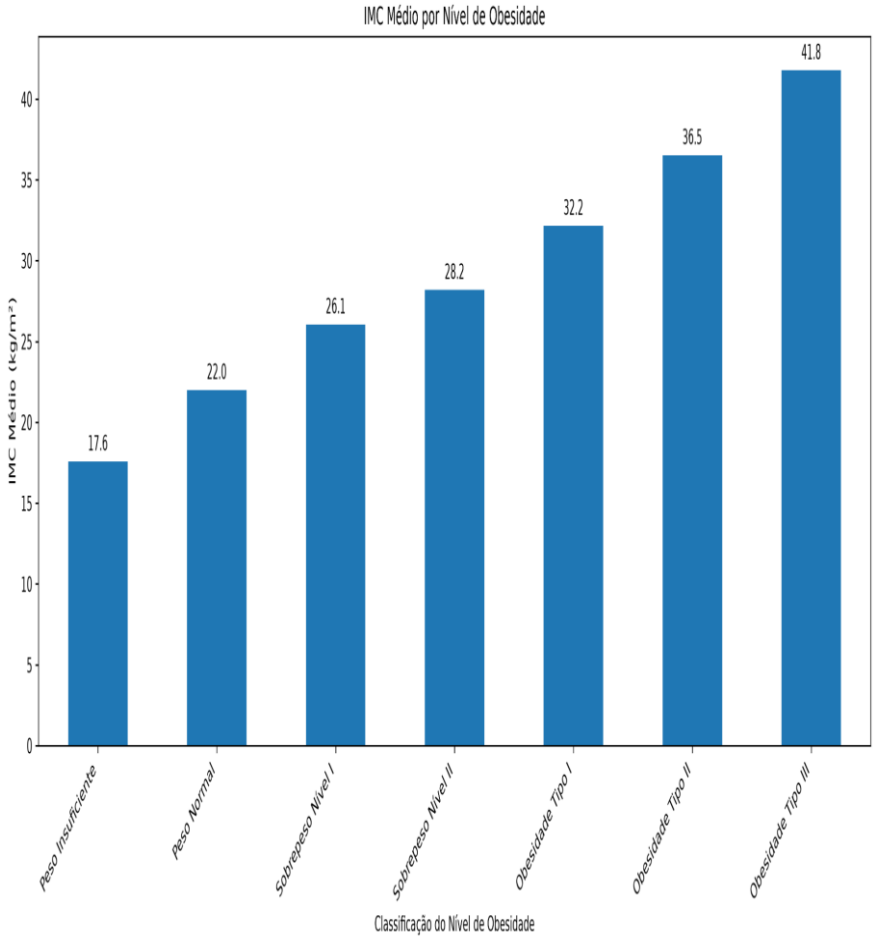
TUE — Tempo de utilização de dispositivos tecnológicos.

Peso e IMC médios por nível de obesidade



Weight (Peso): peso corporal médio dos indivíduos em cada classe de obesidade.

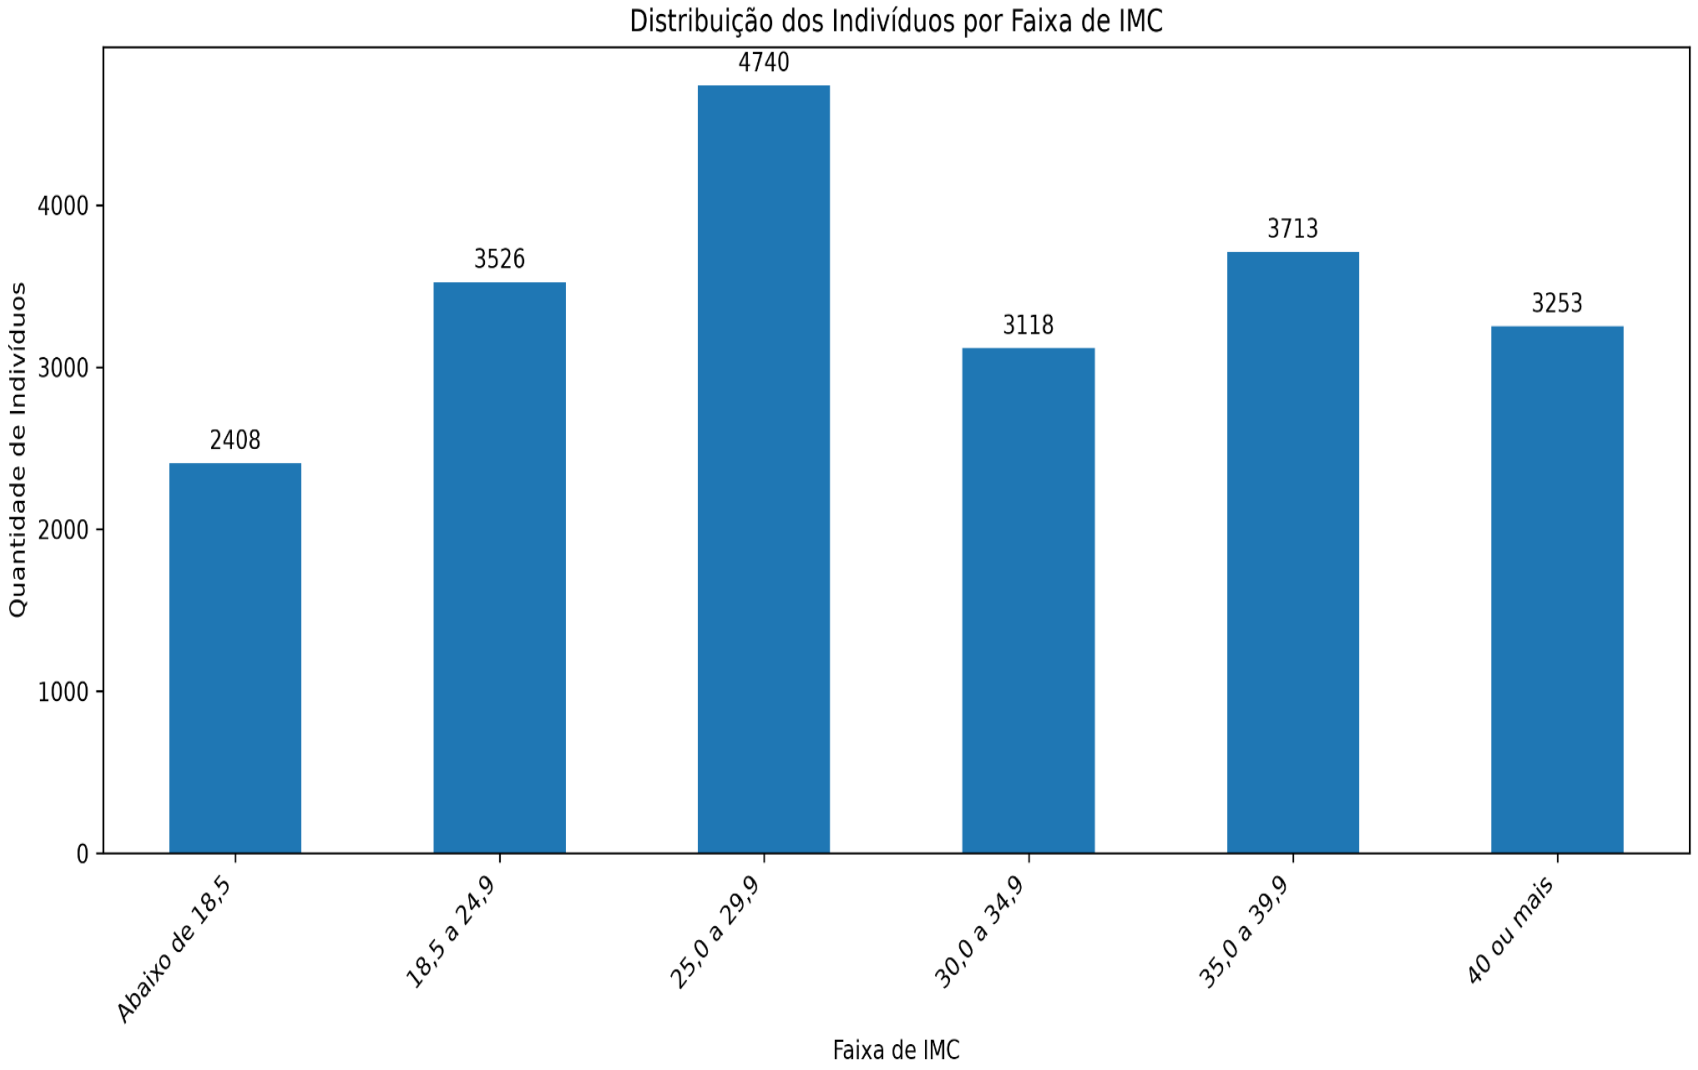
Peso médio por classe



IMC: Índice de Massa Corporal calculado a partir do peso e da altura.

IMC médio por classe

Distribuição dos indivíduos por faixa de IMC



Visualização complementar da concentração dos indivíduos nas faixas de IMC.

Conclusões preliminares da análise exploratória

- As sete classes estão representadas na base, embora com frequências diferentes.
- A maior parte dos registros está concentrada em idades mais jovens.
- Peso e IMC apresentam diferenças claras quando observados entre os níveis de obesidade.
- Algumas variáveis de hábitos apresentam concentração em valores específicos, como NCP, FCVC, FAF e TUE.
- A próxima etapa será preparar os dados e treinar os modelos de classificação.

Preparação dos dados para Machine Learning

- A variável-alvo foi definida como **NObeyesdad** (nível de obesidade).
- X contém as características utilizadas pelo modelo; y contém a resposta que desejamos prever.
- O campo id foi retirado de X por ser apenas um identificador, sem significado preditivo para o indivíduo.
- A variável IMC, criada na etapa exploratória, foi mantida como característica de entrada.

Base original	X — Entradas	y — Alvo
20.758 × 19	20.758 × 17	20.758

Divisão da base em treinamento e validação

O arquivo **train.csv** foi dividido para que o modelo aprenda em uma parte dos dados (80%) e seja avaliado (20%) em registros não utilizados no treinamento.

Treinamento — 80%

16.606 registros

X_train: (16.606, 17)
y_train: (16.606)

Validação — 20%

4.152 registros

X_valid: (4.152, 17)
y_valid: (4.152)

No código em Python foi utilizado a função train_test_split() para dividir a base de dados em conjuntos de treinamento e validação, permitindo treinar o modelo em uma parte dos registros e avaliar seu desempenho em dados que não foram utilizados durante o treinamento.

- random_state = 42: fixa a aleatoriedade da divisão, permitindo reproduzir os mesmos conjuntos de treinamento e validação em novas execuções.
- stratify = y: preserva aproximadamente a proporção das sete classes nos dois conjuntos.

```
# ------------------------------
# 20.1 Divisão dos dados
# ------------------------------
```

```
X_train, X_valid, y_train, y_valid = train_test_split(
    X,
    y,
    test_size=0.20,
    random_state=42,
    stratify=y
)
```

X_train = dados de entrada para treinamento. Contém as características dos indivíduos, como idade, altura, peso, gênero, IMC, atividade física, consumo de água etc.

y_train = respostas corretas para o treinamento. Contém o nível de obesidade (NObeyesdad) correspondente a cada indivíduo de X_train.

Estratificação das classes

O uso de stratify=y manteve a distribuição das classes praticamente igual na base original, no treinamento e na validação.

Classe	Original	Treinamento	Validação
Insufficient_Weight	12,15%	12,15%	12,16%
Normal_Weight	14,85%	14,84%	14,86%
Obesity_Type_I	14,02%	14,02%	14,02%
Obesity_Type_II	15,65%	15,64%	15,66%
Obesity_Type_III	19,49%	19,49%	19,48%
Overweight_Level_I	11,69%	11,69%	11,68%
Overweight_Level_II	12,15%	12,15%	12,14%

Estratificação é uma técnica usada na divisão dos dados para garantir que a proporção das classes da variável-alvo seja aproximadamente mantida nos conjuntos de treinamento e validação.

Pré-processamento das variáveis

As 17 variáveis de entrada foram separadas conforme o tipo de dado.

9 variáveis numéricas

Age • Height • Weight FCVC • NCP • CH2O
• FAF • TUE • IMC

Mantidas sem transformação de escala
para os modelos baseados em árvores.

8 variáveis categóricas

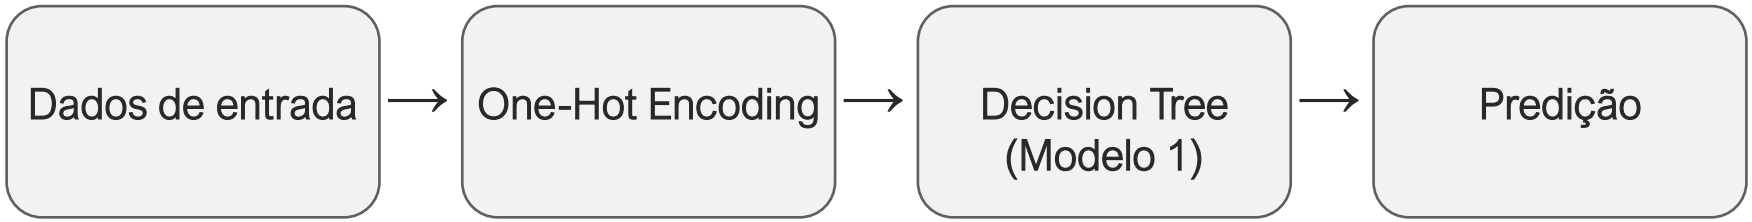
Gender • FAVC • CAEC
• family_history_with_overweight
• SMOKE • SCC • CALC • MTRANS

Convertidas por One-Hot Encoding.

Observação: Eu utilizei o One-Hot Encoding para transformar categorias textuais em colunas numéricas sem criar uma ordem artificial entre elas.

Pipeline de Machine Learning

O Pipeline reúne o pré-processamento e o algoritmo em uma única sequência, garantindo que o mesmo tratamento seja aplicado durante treinamento e validação.



Observação:

- **Pipeline:** sequência organizada de etapas que os dados percorrem até chegar ao objetivo final.
- O mesmo pré-processamento poderá ser reutilizado no próximo modelo: Random Forest.
- **One-Hot Encoding:** Técnica utilizada para transformar categorias textuais em colunas numéricas sem criar uma ordem artificial entre elas.

Modelo 1 — Decision Tree (Árvore de Decisão)

UNICARIOCA Centro Universitário

- A Árvore de Decisão aprende regras de separação a partir das características dos indivíduos.
- O modelo foi treinado com x_train e y_train do objeto de treinamento (80%).
- As previsões foram realizadas sobre os 4.152 registros de x_valid (20%).
- As previsões foram comparadas com y_valid para calcular as métricas de avaliação.

Treinamento: modelo.fit(X_train, y_train) → Validação: modelo.predict(X_valid)

```
modelo_decision_tree.fit(
    X_train,
    y_train
)
```

```
pred_decision_tree = modelo_decision_tree.predict(
    X_valid
)
```

X_train = dados de entrada para treinamento. Contém as características dos indivíduos, como idade, altura, peso, gênero, IMC, atividade física, consumo de água etc.

y_train = respostas corretas para o treinamento. Contém o nível de obesidade (NObeyesdad) correspondente a cada indivíduo de X_train.

Modelo 1 — Resultados — Decision Tree

UNICARIOCA Centro Universitário

Accuracy (Acurácia)	Precision (Precisão)	Recall (Revocação)	F1-score
84,34%	84,26%	84,34%	84,29%
Percentual geral de previsões corretas	Precisão média ponderada	Revocação média ponderada	Equilíbrio entre Precision e Recall

$$Acurácia = \frac{\text{Quantidade de acertos}}{\text{Total de previsões}}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Foram realizadas 4.152 previsões na base de validação.

- ❑ Melhor desempenho: Obesity_Type_III — F1-score de 0,99.
- ❑ Obesity_Type_II também apresentou desempenho elevado — F1-score de 0,95.
- ❑ Maior dificuldade: Overweight_Level_I — F1-score de 0,65.

O resultado mostra que a acurácia geral não substitui a análise do desempenho por classe.

- ❖ **Acurácia (Accuracy):** percentual total de previsões classificadas corretamente pelo modelo.
- ❖ **Precisão:** Precisão do modelo, ou seja, quando o modelo disse que um registro pertence a determinada classe, quantas vezes ele estava correto?
- ❖ **Recall:** mede a capacidade do modelo de identificar corretamente os registros que realmente pertencem a cada classe.
- ❖ **F1-score:** métrica que combina Precision e Recall, permitindo avaliar o equilíbrio entre a precisão das classificações e a capacidade de identificar corretamente os registros de cada classe.

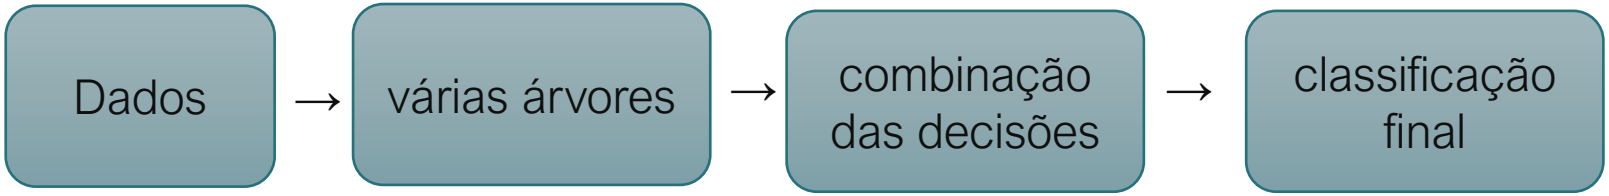
Modelo 1 - Decision Tree - desempenho por classe

Classe	Precision	Recall	F1-score	Support
Peso Insuficiente	88%	89%	89%	505
Peso Normal	79%	78%	79%	617
Obesidade Tipo I	80%	83%	82%	582
Obesidade Tipo II	96%	95%	95%	650
Obesidade Tipo III	99%	1,00	99%	809
Sobrepeso Nível I	67%	64%	65%	485
Sobrepeso Nível II	70%	70%	70%	504

Support = quantidade de registros reais daquela classe presentes na validação.

Modelo 2 - Random Forest (Floresta Aleatória)

- O Random Forest é um algoritmo de classificação formado por várias Árvores de Decisão.
- Neste experimento foram utilizadas 300 árvores (n_estimators = 300).
- Cada árvore participa da classificação e o resultado final é obtido pela combinação das decisões da floresta.
- Foram utilizados os mesmos conjuntos X_train, y_train, X_valid e y_valid empregados na Decision Tree.
- Isso permite comparar os dois modelos utilizando exatamente os mesmos dados de treinamento e validação.



Modelo 2 - Random Forest (Floresta Aleatória)

UNICARIOCA Centro Universitário

Accuracy (Acurácia)	Precision (Precisão)	Recall (Revocação)	F1-score
90,58%	90,56%	90,58%	90,55%
Previsões corretas no conjunto de validação	Média ponderada entre as sete classes	Média ponderada entre as sete classes	Equilíbrio entre Precision e Recall

Quantidade de previsões realizadas na validação: 4.152

- Obesity_Type_III apresentou Precision, Recall e F1-score iguais a 100%.
- Obesity_Type_II apresentou F1-score de 97%.
- As maiores dificuldades permaneceram em Overweight_Level_I (F1 = 79%) e Overweight_Level_II (F1 = 80%).

Comparação — Decision Tree × Random Forest

Métrica	Decision Tree	Random Forest	Diferença
Accuracy	84,34%	90,58%	+6,24%
Precision	84,26%	90,56%	+6,30%
Recall	84,34%	90,58%	+6,24%
F1-score	84,29%	90,55%	+6,26%

Na mesma base de validação, o Random Forest apresentou resultados superiores nas quatro métricas avaliadas.

Conclusão da Modelagem

Os dois modelos foram treinados e avaliados com a mesma divisão dos dados.

A Decision Tree alcançou 84,34% de acurácia na base de validação.

O Random Forest alcançou 90,58% de acurácia e também apresentou melhores valores de Precision, Recall e F1-score.

Com base na comparação realizada, o Random Forest foi selecionado para o treinamento final e para gerar as previsões do test.csv.

Modelo final — Random Forest

Base utilizada

20.758

Todos os registros disponíveis no train.csv

Características

17

Variáveis de entrada após retirada do id

Random Forest

300 árvores

Mesmo pré-processamento usado na validação

- Após a comparação dos modelos, o Random Forest foi treinado novamente utilizando toda a base conhecida.
- A variável-alvo continuou sendo NObeyesdad e o IMC foi mantido como característica de entrada.
- Os 4.152 registros anteriormente reservados para validação voltaram a participar do treinamento final.

Aplicação do modelo final ao test.csv

Registros do test.csv

13.840

Indivíduos sem a variável-alvo

Características

17

Mesmas características utilizadas no treinamento

Previsões geradas

13.840

Uma previsão de NObeyesdad por id

Conferência das colunas de treinamento e teste:

X.columns == X_test.columns → True

- A coluna id foi retirada antes da predição, pois funciona apenas como identificador.

- O Pipeline aplicou o mesmo One-Hot Encoding e, em seguida, o Random Forest realizou as classificações.

Geração e validação do submission.csv

UNICARIOCA Centro Universitário

Dimensão	Colunas	Valores nulos	IDs conferidos
13.840 × 2	**2**	**0**	**OK**
Formato final do arquivo	id + NObeyesdad	Nenhum valor ausente	Mesma sequência do test.csv

Classes presentes nas previsões

1. Insufficient_Weight
2. Normal_Weight
3. Obesity_Type_I
4. Obesity_Type_II
5. Obesity_Type_III
6. Overweight_Level_I
7. Overweight_Level_II

Resultado:
Arquivo submission.csv gerado e validado

Conclusão (antes de enviar ao Kaggle)

UNICARIOCA
Centro Universitário

- A análise exploratória permitiu compreender a estrutura, as variáveis e a distribuição das sete classes de obesidade.
- Foram comparados dois modelos: Decision Tree e Random Forest, utilizando a mesma base de validação.
- A Decision Tree alcançou 84,34% de acurácia; o Random Forest alcançou 90,58%, além de melhores valores de Precision, Recall e F1-score.
- O Random Forest foi então treinado com os 20.758 registros do train.csv e aplicado aos 13.840 registros do test.csv.
- O submission.csv foi gerado com 13.840 previsões, sem valores nulos e com os IDs conferidos.